

TESI DI LAUREA

**Analisi di un flow-based Intrusion Detection System basato su
machine learning e sua estensione a formati di netflow
differenti: il caso di Stratosphere**

Candidato:

Michele Murgolo

Matricola 101851

Relatore:

Prof. Mirco Marchetti

La pagina della dedica

Sommario

Stratosphere Testing Framework (stf) è una framework di ricerca sulla sicurezza della rete per analizzare i modelli comportamentali delle connessioni di rete nel Progetto Stratosphere. Il suo obiettivo è aiutare i ricercatori a trovare nuovi comportamenti malware, etichettare tali comportamenti, creare i loro modelli di traffico e verificare gli algoritmi di rilevamento. Stf funziona utilizzando algoritmi di apprendimento automatico sui modelli comportamentali. L'obiettivo di Stratosphere Project è creare un IPS comportamentale (Intrusion Detection System) in grado di rilevare e bloccare i comportamenti dannosi nella rete. Come parte di questo progetto, stf viene utilizzato per generare modelli altamente attendibili di traffico dannoso consentendo una verifica automatica delle prestazioni di rilevamento. Il framework genera questi modelli da file in formato binetflow, il DIEF salva il traffico internet in file formato flows. Si è scritto un programma in python3 che esegue la conversione batch da flows a binetflow. I file che il programma deve convertire sono numerosi e di grandi dimensioni, ogni giorno di traffico ha una dimensione media pari a 150Mb. Per effettuare una conversione efficiente si è utilizzato un approccio multicore che ha permesso di ottenere uno speed up lineare della conversione.

Indice

1	Introduzione	9
2	Stato dell'arte	13
2.1	Malware	13
2.2	Botnet	14
2.3	Botnet Detection	17
2.4	Intrusion Detection and Prevention System	18
2.4.1	Perchè usare IDPS	21
2.4.2	Tipi di IDPS	21
2.4.3	Metodi di rilevamento	22
2.5	Machine learning	23
2.5.1	Apprendimento supervisionato	24
2.5.2	Apprendimento non supervisionato	25
2.5.3	Apprendimento per rinforzo	28
2.5.4	Modelli probabilistici	29
3	Analisi del problema	31
3.1	Analisi traffico di rete	31

3.1.1	Network Flow	31
3.1.2	Packet Capture	32
3.1.3	NetFlow	32
3.2	Strumenti di monitoraggio e analisi del traffico di rete	35
3.2.1	Audit Record Generation and Utilization System	35
3.2.2	nProbe	36
3.2.3	Confronto tra i network flow	37
3.3	Stratosphere IPS	38
3.3.1	Architettura	38
3.3.2	Modelli comportamentali	39
3.4	Problematiche dovute all'utilizzo di due diversi formati	41
3.5	Presentazione del problema	41
4	Soluzione proposta	43
4.1	Conversione	43
4.2	Automatizzazione conversione	44
4.3	Rendere efficiente la conversione	45
4.3.1	Possibili soluzioni	45
4.3.2	Scelta effettuata	47
5	Esperimenti e risultati	49
5.1	Software utilizzati	49
5.2	Installazione Stratosphere IPS	50
5.3	Installazione di Argus	51
5.4	Utilizzo del programma stf	51

<i>INDICE</i>	7
5.5 Prestazioni	53
5.5.1 Benchmark	53
5.5.2 Metrica delle prestazioni parallele	54
5.6 Modelli comportamentali	57
6 Conclusioni	59
6.1 Prestazioni	59

Capitolo 1

Introduzione

La continua digitalizzazione nel mondo sta mettendo le aziende a rischio di attacchi informatici più che mai. Negli ultimi anni, grazie alla crescente adozione di servizi cloud e mobili, la sicurezza delle informazioni ha subito un profondo cambio di paradigma dai tradizionali strumenti di protezione verso l'individuazione di attività dannose all'interno delle reti aziendali.

I metodi di attacco sempre più sofisticati utilizzati dai criminali informatici in diverse recenti violazioni della sicurezza su larga scala indicano chiaramente che gli approcci tradizionali alla sicurezza delle informazioni non possono più tenere il passo.

L'analisi dei dati è l'elemento chiave per sfruttare la resilienza informatica. Con attacchi sempre più avanzati e persistenti e il semplice fatto che ogni organizzazione deve proteggersi da tutte le varietà di attacchi mentre un aggressore ha bisogno solo di un tentativo riuscito, le organizzazioni devono ripensare ai propri concetti di sicurezza informatica: Devono andare oltre la pura prevenzione.

big data security analytics è l'approccio alla base di questo miglioramento del rilevamento. Il rilevamento deve essere in grado di identificare i modelli di utilizzo che cambiano ed eseguire analisi complesse su una varietà di fonti di dati che vanno dai registri di server e applicazioni agli eventi di rete e alle attività degli utenti. Ciò richiede di eseguire analisi su grandi quantità di dati correnti e storici.

Negli ultimi anni è emersa una nuova generazione di soluzioni di analisi della sicurezza, in grado di raccogliere, archiviare e analizzare enormi quantità di dati. Questi dati vengono analizzati utilizzando vari algoritmi di correlazione per rilevare le anomalie e quindi identificare possibili attività dannose. L'industria ha finalmente raggiunto il punto in cui gli algoritmi di intelligenza artificiale per l'elaborazione di dati su larga scala sono diventati accessibili utilizzando framework prontamente disponibili.

Ciò consente di combinare analisi storiche e in tempo reale e identificare nuovi incidenti che potrebbero essere correlati ad altri che si sono verificati in passato. Insieme a fonti di intelligence di sicurezza esterne che forniscono informazioni aggiornate sulle ultime vulnerabilità, ciò può facilitare notevolmente l'identificazione di attacchi informatici in corso sulla rete.

È con l'intenzione di utilizzare queste tecnologie che viene presentato in questa tesi un software per la cattura, l'archiviazione e l'analisi di enormi quantità di dati. Come mostrerò nei seguenti capitoli, l'utilizzo di questi software comporta una organizzazione dei dati notevole e verranno evidenziati in special modo le difficoltà nella gestione dei diversi formati che questi tipi di tecnologie comportano. Questa tesi metterà in evidenza l'eterogeneità dei software che hanno sempre contraddistinto l'informatica e le soluzioni scelte per risolvere tali problemi.

Nel secondo capitolo verranno in primo luogo presentate le minacce provenienti dalla rete, con particolare enfasi sui tipi di attacchi su larga scala. Successivamente verranno presentato lo stato dell'arte dei sistemi di difesa utilizzati ad oggi per contrastare questi tipi di attacchi. In conclusione del capitolo verrà discussa la scelta delle tecnologie utilizzate in questa tesi.

Nel terzo capitolo verrà introdotto uno speciale tipo di file che sarà il principale punto di enfasi in questa tesi. Dopo di che verranno presentati i differenti tipi di formati che questo file può assumere e le problematiche dovute ai diversi standard in uso oggi. Dopo una descrizione dettagliata delle varie differenze tra i formati verrà introdotto il software che farà uso di questi file e si presenterà l'utilizzo che questi file hanno in relazione alle tecnologie utilizzate. Infine troverà spazio la presentazione del problema da affrontare.

Nel quarto capitolo sarà descritto in dettaglio l'installazione del software di cui si farà uso. In seguito si descriveranno le scelte effettuate per risolvere il problema nell'uso di diversi formati di file e l'automatizzazione di tale soluzione. Infine saranno presentati i diversi metodi atti a perfezionare l'automatizzazione per renderla efficiente e la scelta che è stata effettuata.

Nel quinto capitolo verranno mostrati i risultati dei test e i benchmark effettuati con lo scopo di confermare al livello pratico quanto mostrato sotto forma teorica nel capitolo precedente. Saranno descritte in modo dettagliato le condizioni sotto le quali sono stati effettuati i test e limiti della scalabilità della soluzione. Il tutto verrà seguito da grafici esplicativi.

Nel sesto capitolo infine, verrà fatto un riassunto della tesi ribadendo l'obiettivo, cosa si è svolto in questa tesi e i risultati ottenuti.

Capitolo 2

Stato dell'arte

In questo capitolo verranno discussi i principali lavori che sono stati fatti durante l'ultimo decennio in letteratura. Si procede col fornire un'introduzione preliminare sui concetti che verranno utilizzati durante questa tesi.

2.1 Malware

Il termine malware è una combinazione delle parole *malicious* e *software*. Il malware rappresenta quei programmi software progettati per danneggiare o effettuare azioni indesiderate su un sistema informatico. [6]

Gli obiettivi che può avere un malware sono molteplici e sono in continua evoluzione. Il malware, a seconda dello scopo per cui è stato creato e alle sue caratteristiche, viene classificato nei seguenti modi:

Virus Prendono il nome dai virus in campo biologico e si comportano in modo analogo, sono programmi che si replicano sul computer che hanno infettato e si predispongono ad infettare nuovi computer mediante mezzi di trasmissione quali email e chiavette USB. [10]

Spyware Il termine Spyware è una combinazione delle parole *Spy* e *Software*. È un software che viene installato sul computer della vittima a sua insaputa e che raccoglie informazioni. Uno spyware è oggetto di controversia perchè può essere utilizzato negli ambienti lavorativi per controllare le ricerche dei dipendenti o per controllare l'attività dei propri figli su internet. Anche se utilizzato per scopi più innocui può comunque violare

la privacy dell'utente. [11]

Usi più scorretti di programmi spyware prevedono di tracciare la cronologia internet di un utente per inviare pubblicità mirata, accedere alle password degli account in uso sul computer infetto e/o alle informazioni bancarie. Le informazioni raccolte attraverso l'uso di spyware possono essere utilizzate in vari modi, l'uso più frequente e più remunerativo ad oggi è quello di rivendere tali informazioni a dei terzi. [16]

Backdoor Tradotto letteralmente come *porta sul retro*, è un metodo utilizzato per avere un accesso privilegiato e spesso segreto che aggira il sistema di autenticazione previsto. Lo scopo di una backdoor è quello di permettere una connessione in remoto al computer vittima per prenderne il controllo.

Trojan Il cavallo di Troia fu una macchina da guerra che, secondo la leggenda, fu usata dai greci per espugnare la città di Troia. Questo termine è entrato nel linguaggio comune per indicare uno stratagemma con cui penetrare le difese. Nell'ambito dei malware il trojan è un software che si nasconde all'interno di un altro programma all'apparenza innocuo e che, se eseguito, esegue anche il codice del trojan [13]. Oggi col termine trojan ci si riferisce principalmente ai malware ad accesso remoto. Spesso vengono utilizzati per installare backdoor sui sistemi bersaglio. [15]

I malware erano inizialmente usati per compiere azioni dolose sia da hacker malintenzionati che dai governi per sottrarre informazioni personali, inviare spam e commettere frodi. [5] [7]

L'evoluzione e lo sviluppo di internet hanno portato ad un incremento degli utenti connessi sempre maggiore. Questa crescita di internet ha spostato l'obiettivo dei malware che vengono usati sempre di meno per compiere azioni dolose. Fin dal 2003 la maggior parte dei malware sono stati creati per prendere il controllo dei computer dell'utente vittima per scopi illeciti [7]. Vengono usati computer zombie per l'invio di email di spam o per effettuare attacchi distribuiti Denial of Service (DDoS).

2.2 Botnet

Nella sua forma più semplice una Botnet è un gruppo di computer che sono stati infettati da un malware che consente al suo controller, detto anche master, di avere il controllo sulle macchine infettate. Le Botnet sono usate dal master per compiere operazioni illecite ad insaputa della vittima. Una volta infetto, il computer della vittima prende il nome

di zombie. [2]

Per aggiungere un computer ad una botnet si infetta il computer vittima con un malware che installa una backdoor in grado di consentire al master di avere accesso remoto al computer infettato dal malware. Il master ha così accesso ad un sistema gigantesco di computer zombie pronti ad essere attivati ed eseguire i suoi ordini. Le botnet rilevate e studiate nella storia dimostrano come questi sistemi possano arrivare a contenere anche milioni di computer infetti. [2]

I componenti di una botnet sono i seguenti:

Master Il master è il computer che ha creato la botnet e che ne ha il controllo remoto. È detto C&C (Command and Control) il programma che dà i comandi da eseguire tramite un canale nascosto sul computer della vittima.

Control protocol Il protocollo utilizzato dal master per comunicare con i computer zombie.

Computer zombie Computer connesso ad internet che è stato infettato attraverso dei virus o trojan e che può essere utilizzato in modo remoto.

Nella figura seguente viene rappresentato una possibile architettura di una botnet. Il master è il computer che controlla in modo remoto i computer zombie attraverso dei server C&C.




Figura 2.1: Esempio architettura botnet

I principali attacchi informatici effettuati attraverso l'utilizzo delle botnet sono vari: possono essere spam, DDoS, click fraud, phishing e bitcoin mining per citarne alcuni. È quindi evidente come l'utilizzo delle botnet sia al fine di un guadagno economico.

Spam È l'invio tramite posta elettronica di messaggi ad alta frequenza contenenti truffe o pubblicità.

DDoS Acronimo di Distributed Denial of Service, è un tipo di attacco in cui si mira a far esaurire le risorse di un sistema informatico affinché non riesca più a fornire servizio. Per fare ciò si effettuano moltissime richieste al sistema per farlo rallentare o nei casi più estremi rendere inutilizzabile.

Click fraud Questo tipo di frode si verifica sulla pubblicità su internet di tipo pay per click. Questo tipo di pubblicità genera quantità di denaro in base al numero di click effettuati sull'annuncio pubblicitario. Le botnet sfruttano questo tipo di pubblicità utilizzando computer zombie per cliccare in massa gli annunci pubblicitari.

Phishing Con l'aumento di transazioni effettuate su internet il phishing è diventato sempre più comune [24]. Il phishing è un tipo di truffa utilizzato per ottenere informazioni da utenti non esperti attraverso l'impersonazione di fonti attendibili [9].

Bitcoin mining I bitcoin sono una criptovaluta che a differenza dei soldi, che vengono stampati da un governo centrale, vengono creati risolvendo operazioni matematiche complesse. Una botnet utilizza i computer zombie come unità di calcolo a cui far eseguire queste operazioni complesse.

2.3 Botnet Detection

Le botnet sono diventate il metodo preferito per lanciare attacchi su internet, sono una seria minaccia poiché possono inviare malware in modo coordinato e istantaneo da numerosi bot [26]. Gli attacchi perpetrati dalle botnet si distinguono per il volume del traffico dati e per la velocità con cui sono commessi, questi attacchi riducono in modo significativo i tempi di risposta per difendersi.

È stimato che ci sono milioni di bot su internet ogni giorno, è quindi chiaro che le botnet sono diventate la minaccia più seria per la sicurezza su internet [26].

Sono vari i metodi per cercare di individuare botnet su internet, quello che si è visto in questa tesi è basato sul modello comportamentale.

Botnet detection based on Network Behavior Presenta un approccio per identificare le attività di C&C delle botnet utilizzando le statistiche dei flow di rete come la larghezza di banda e la tempistica dei pacchetti [26].

Le botnet sono difficili da individuare siccome l'host che lancia l'attacco non è visibile direttamente dalla vittima perché nascosto da un layer di zombie. L'attacco, inoltre, viene diviso nell'insieme dei bot in un periodo di tempo.

Come descritto in figura 2.2, il computer vittima non vede un attacco unico, ma un insieme di attacchi da una moltitudine di computer diversi che nascondono il botmaster.

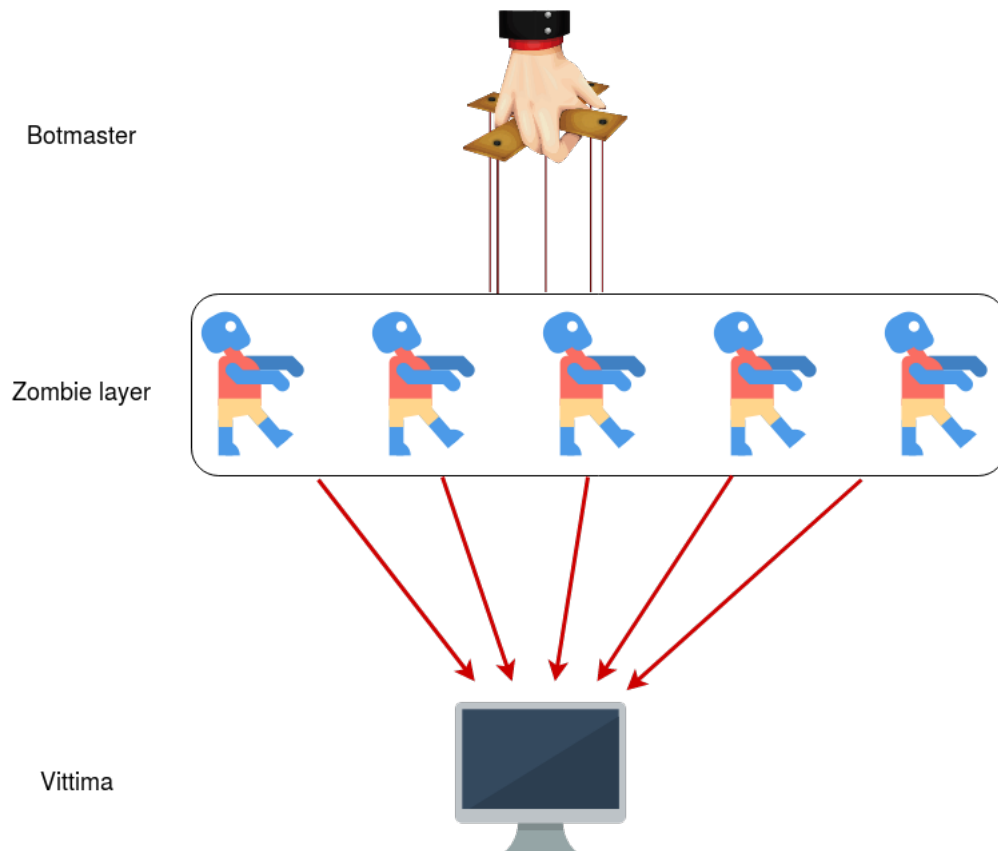


Figura 2.2: Zombie layer

2.4 Intrusion Detection and Prevention System

Un'intrusione si verifica quando un aggressore tenta di entrare o interrompere le normali operazioni di un sistema informativo, quasi sempre con l'intento di fare del male [23]. In questa sezione verranno presentati dei dispositivi utilizzati per identificare accessi non autorizzati ai computer o alle reti locali. Questi dispositivi possono essere utili per il rilevamento di botnet [26].

I sistemi di rilevamento delle intrusioni sono gli "allarmi antifurto" del campo della sicurezza informatica. L'obiettivo è difendere un sistema con un allarme che viene emesso ogni volta che la sicurezza del sito è stata compromessa [18].

Un IDPS è un dispositivo software o hardware utilizzato per identificare intrusioni a computer o reti locali. Ci sono varie classi di intrusione che vanno rilevate: si possono verificare situazioni in cui un utente ruba una password, utenti legittimi che abusano

dei loro privilegi o hacker che usano script trovati in rete per attaccare il sistema. Le intrusioni sono varie e non è possibile elencarle tutte.

Un IDPS è composto da quattro componenti [23]:

- **Sensori**, sono utilizzati per ricevere informazioni dalla rete o dai computer.
- **Console**, utilizzata per monitorare lo stato della rete e dei computer.
- **Motore**, analizza i dati prelevati dai sensori e provvede a individuare eventuali falle nella sicurezza.
- **Database**, memorizza le regole utilizzate per identificare violazioni di sicurezza.

Di seguito è presente un'immagine che descrive i componenti di un IDPS. I pacchetti in entrata e uscita dalla rete sono ricevuti da un sensore che raccoglie il traffico dati, successivamente il motore analizza i dati prelevati dai sensori con le regole presenti nel database.




Figura 2.3: Esempio di un IDS

Un'attuale estensione degli IDS sono i sistemi di prevenzione delle intrusioni detti IPS, che possono rilevare un'intrusione e impedire che l'intrusione attacchi con successo tramite una risposta attiva. Gli IPS usano diverse tecniche di risposte attive, che possono essere suddivise nei seguenti gruppi [20]:

- **terminare** la connessione internet o la sessione utente che sta eseguendo l'attacco
- **bloccare** l'accesso all'obiettivo e agli obiettivi simili all'utente o indirizzo IP che sta tentando un'intrusione
- **cambiare** l'ambiente di sicurezza modificando la configurazione di altri controlli di sicurezza per interrompere l'attacco, come la riconfigurazione delle regole di un firewall. Alcuni IPS possono anche applicare della patch di sicurezza a degli host se l'IPS rileva che l'host presenta delle vulnerabilità.

Poiché i due sistemi coesistono spesso, il termine combinato sistema di rilevamento e prevenzione delle intrusioni (IDPS) viene generalmente utilizzato per descrivere le attuali tecnologie anti-intrusione [20].

2.4.1 Perché usare IDPS

Dispositivi di tipo IDPS sono utili per le difese di sistemi informatici per molteplici ragioni:

- **defense in depth**, l'utilizzo di un dispositivo IDPS unito a firewall, controlli di accesso e autenticazione e antivirus permette la realizzazione di un meccanismo di protezione multi-livello
- **documentazione**, i dati acquisiti sono utili anche per il miglioramento continuo della qualità, gli IDPS raccolgono costantemente informazioni sugli attacchi che hanno compromesso con successo gli strati esterni dei controlli di sicurezza, per esempio di un firewall. Queste informazioni possono essere utilizzate per identificare e riparare le vulnerabilità esposte dagli attacchi, questo aiuta l'organizzazione ad accelerare il processo di risposta agli incidenti e ad apportare miglioramenti continui. Inoltre, nei casi in cui un IDPS non riesce a prevenire un'intrusione, può ancora assistere nella revisione fornendo informazioni su come si è verificato l'attacco, i dettagli su cosa ha fatto l'intruso e i metodi utilizzati. Gli IDPS possono anche fornire informazioni forensi che possono essere utili per motivi legali qualora l'attaccante venga catturato [20]
- **insider threat**, gli attacchi non sempre arrivano dall'esterno, con questi dispositivi è possibile difendersi anche da intrusioni che avvengono all'interno della rete

Il miglior motivo per installare un IDPS è per la loro funzione di deterrente. Se gli utenti esterni e interni sanno che un'organizzazione ha un sistema di rilevamento e prevenzione delle intrusioni sono meno propensi a sondare o tentare di comprometterla [20].

2.4.2 Tipi di IDPS

Gli IDPS possono essere di due tipi in base al target su cui vengono applicati: possono essere basati su rete o su host. Un IDPS basato su rete è focalizzato sulla protezione delle risorse di rete. Due sottotipi di IDPS basati su rete sono [20]:

- **wireless IDPS**, si concentra sulle reti wireless

- **network behavior analysis**, analizza i flow di traffico sulla rete nel tentativo di riconoscere dei modelli comportamentali anomali

Gli IDPS basati su host sono focalizzate sulla protezione dei server o dei singoli host.

Network-Based IDPS Un IDPS basato sulla rete, detto NIDPS, è installato su un computer o dispositivo collegato ad un segmento della rete e ne monitora il traffico alla ricerca di indicazioni di attacchi. Un IDPS basato su rete può rilevare molti più attacchi rispetto ad un IDPS basato su host, ma richiede una configurazione e manutenzione più complessa.

Host-Based IDPS Un IDPS basato su host, detto HIDPS, risiede su un particolare computer o server e monitora l'attività solo su quel sistema.

2.4.3 Metodi di rilevamento

Gli IDPS utilizzano vari metodi di rilevamento per monitorare e valutare il traffico di rete. I metodi principali sono [18]:

Signature detection Questo metodo di rilevamento delle intrusioni esamina il traffico di rete alla ricerca di modelli che corrispondono a firme note, ovvero modelli di attacco preconfigurati e predeterminati. Questo metodo si basa sul presupposto che in qualsiasi caso riusciamo a definire un comportamento legale o illegale e a confrontarlo di conseguenza il comportamento osservato. Un vantaggio di questo approccio è che, avendo un modello con cui confrontare il comportamento che si sta osservando, non esistono falsi positivi. È inoltre veloce e semplice in quanto deve soltanto effettuare confronti con modelli illegali già noti. Uno svantaggio di questo approccio è che si possono verificare molti falsi negativi, cioè i comportamenti dannosi che non vengono segnalati. Questo si verifica perché questi sistemi sfruttano regole per rilevare le intrusioni salvate su di un database, è quindi estremamente importante tenere aggiornato il database con tutti i possibili comportamenti dannosi.

Anomaly detection In questo tipo di rilevamento si parte con il presupposto che qualcosa di anormale sia molto probabilmente sospetto, si cercano quindi anomalie nel traffico. È quindi necessario uno studio anticipato della rete per capire cosa sia normale per il soggetto osservato. Si decide poi quanto è possibile discostarsi dal tipo di attività normale. Questo tipo

di rilevamento guarda comportamenti che sono improbabili che si verifichino dallo studio effettuato sul traffico normale. Il vantaggio di questo metodo è che indipendente dal tipo di intrusione ed è possibile utilizzare algoritmi di *machine learning* che apprendono da soli cosa è normale osservando il traffico per un lungo periodo di tempo. Gli svantaggi sono la difficoltà di creare modelli e l'imprecisione che hanno questi modelli che danno vita a molti falsi positivi e falsi negativi.

2.5 Machine learning

Il machine learning, tradotto in italiano come apprendimento automatico, rappresenta uno degli sviluppi più prolifici dell'intelligenza artificiale moderna [19]. L'enfasi dell'apprendimento automatico è sulla capacità del sistema di adattarsi o cambiare, in genere in risposta a qualche forma di esperienza fornita al sistema. Dopo l'apprendimento ci si aspetta che il sistema migliori le prestazioni future sullo stesso compito o lavori simili.

Negli ultimi anni l'apprendimento automatico ha preso sempre più piede ed è ormai utilizzato quasi ovunque [19]. Alcuni esempi di applicazioni di machine learning nel mondo reale sono il controllo di robot autonomi in grado di navigare da soli, si pensi alle macchine con pilota automatico che stanno entrando in commercio negli ultimi anni come la Tesla di Elon Musk; il filtro dello spam nelle email, il riconoscimento della calligrafia impiegato da software OCR, il riconoscimento vocale degli assistenti presenti su dispositivi come Google Home, Amazon Alexa o Apple HomePod; il rilevamento dei volti nelle fotocamere digitali e così via. Per problemi come il riconoscimento vocale gli algoritmi basati sul machine learning superano tutti gli approcci che sono stati tentati fino ad oggi [21].

Generalmente esistono tre paradigmi di apprendimento [25].

Apprendimento supervisionato Al computer vengono forniti una serie di input insieme ai corrispondenti output desiderati. Si vuole trovare quella funzione che dato un input non conosciuto calcola l'output. L'obiettivo è quello di fare una previsione basata su proprietà conosciute apprese dai dati in input.

Apprendimento non supervisionato Vengono forniti esempi che consistono di soli input, ma non viene fornito alcun valore di output. L'obiettivo è scoprire nuove proprietà nei dati forniti in input attraverso l'ottimizzazione di un principio di apprendimento.

Apprendimento per rinforzo Osservando l'ambiente corrente e ottenendo qualche input, il computer compie un'azione che cambia l'ambiente, riceve poi una valutazione positiva o negativa sull'azione compiuta. L'obiettivo è compiere una serie di azioni tali da massimizzare la valutazione ricevuta.

2.5.1 Apprendimento supervisionato

Al computer supervisionato vengono forniti dei dati chiamati *training data*. Questi dati sono dei campioni, ognuno dei quali consiste in un input insieme all'output desiderato.

In base al valore di output si distinguono due diversi problemi:

- **Classificazione** Se il valore di output è discreto, ad esempio l'appartenenza o la non appartenenza ad una determinata classe.
- **Regressione** Se il valore dell'output è un valore reale continuo in un determinato range.

In entrambi i problemi si vuole trovare una funzione h , che dato un input non conosciuto stima il valore dell'output. L'obiettivo dei problemi di apprendimento supervisionato è quello di fare una predizione basata su proprietà conosciute apprese dai dati di input.

La figura seguente descrive un problema di apprendimento supervisionato, dove l'algoritmo di apprendimento automatico prende in input un insieme di esempi da cui impara una funzione che gli permette di fare previsioni.




Figura 2.4: Apprendimento supervisionato

2.5.2 Apprendimento non supervisionato

In questa categoria vengono forniti esempi con relative feature in input, ma non viene fornito alcun valore di output, quindi si hanno a disposizione dati non etichettati. L'obiettivo di questi algoritmi è quello di trovare delle strutture all'interno di questi dati non etichettati. Se si vogliono identificare dei raggruppamenti di elementi simili, è un problema di Clustering.

Clustering È un tipico esempio di apprendimento non supervisionato in cui, dato un insieme di dati non etichettati, l'obiettivo è quello di individuare dei raggruppamenti, detti cluster, quanto più possibile coerenti.

2.5.2.1 K-Means

L'algoritmo K-Means è l'algoritmo di clustering più conosciuto e più utilizzato. Permette di suddividere un insieme di oggetti in K gruppi sulla base dei loro attributi.

Si assume che gli attributi degli oggetti possano essere rappresentati come vettori, e che quindi formino uno spazio vettoriale. Dal *dataset* fornito vengono inizializzati n punti detti centroidi per ogni cluster che è necessario identificare.

Nell'esempio in figura vengono inizializzati due centroidi con una croce rossa e blu.




Figura 2.5: Algoritmo k-means - Inizializzazione

L'algoritmo segue una procedura iterativa che ripete due passi, il primo è il passo di assegnazione ai cluster, mentre il secondo è il passo di spostamento dei centroidi. Il primo passo di assegnazione ai cluster controlla la distanza di ogni punto del dataset dai centroidi e assegna ciascun punto al centroide che gli è più vicino. L'esempio in figura rappresenta questo primo passo: i punti più vicini al centroide rosso sono stati colorati di rosso, mentre quelli più vicini al centroide blu sono stati colorati di blu.




Figura 2.6: Algoritmo k-means - Passo 1

Il secondo passo consiste nel calcolare la media di tutti i punti nel dataset che appartengono ad un cluster e muovere in quella posizione il centroide del cluster.




Figura 2.7: Algoritmo k-means - Passo 2

L'algoritmo continua a ripetere questi due passi fino a quando i centroidi non si spostano più, il che significa che l'algoritmo ha raggiunto la convergenza e i due cluster sono stati individuati.




Figura 2.8: Algoritmo k-means - Convergenza

2.5.3 Apprendimento per rinforzo

A differenza dell'apprendimento non supervisionato l'apprendimento per rinforzo viene indirizzato dalla valutazione esterna. Inoltre a differenza dell'apprendimento supervisionato in cui viene specificato l'output corrispondente ad un input, nell'apprendimento per rinforzo viene fornita solo una valutazione sull'azione compiuta.

In aggiunta, questo tipo di apprendimento è caratterizzato da un processo dinamico in fasi discrete: ad ogni passo, osservando l'ambiente circostante e ottenendo qualche input, il computer compie un'azione e si sposta in un nuovo stato, venendo premiato o punito in base all'azione effettuata [19].

2.5.3.1 Processo decisionale di Markov

L'apprendimento per rinforzo è strettamente correlato con il processo decisionale di Markov [19], che consiste in una serie di stati $s_0, s_1, \dots, s_t, s_{t+1}, \dots$. Allo stato s_t , un'azione $a_t = \pi(s_t)$ è selezionata da un insieme A di azioni intraprese in funzione dello stato

π , che fa muovere l'ambiente per raggiungere lo stato successivo s_{t+1} e la valutazione v_{t+1} associata con la transizione (s_t, a_t, s_{t+1}) viene assegnata. L'obiettivo è ottenere la valutazione più alta possibile, cioè di massimizzare

$$R = \sum_{t=0}^{N-1} r_{t+1}$$

con N istante di tempo in cui lo stato finale è raggiunto.

2.5.4 Modelli probabilistici

I metodi probabilistici sono fondamentali per l'apprendimento automatico [19].

2.5.4.1 Modelli di Markov

Le serie temporali e, più in generale le sequenze, sono una forma di dati strutturati che rappresenta un elenco di osservazioni per le quali è possibile definire un ordine completo, come ad esempio il tempo in una sequenza temporale.

Sia una sequenza di lunghezza T , $y_n = y_1, \dots, y_T$. Il termine y_t indica l'osservazione t -esima rispetto all'ordine totale. Siccome gli elementi che compongono la sequenza non sono indipendenti e identicamente distribuiti, la distribuzione congiunta di un modello probabilistico per y è $P(Y_1, \dots, Y_T)$.

Per osservazioni y_t a valore discreto la distribuzione congiunta cresce esponenzialmente con le dimensioni del dominio di osservazione. Per ridurre la parametrizzazione si usano le *Catene di Markov*. Le Catene di Markov semplificano assumendo che un'osservazione che si verifica in una posizione t della sequenza dipende solo da un numero limitato di predecessori rispetto all'ordine completo. Ciò significa che in una serie temporale un'osservazione al tempo presente tiene conto soltanto di un numero limitato di osservazioni del passato.

Le Catene di Markov stanno alla base dei *Modelli di Markov nascosti* (HMM).

2.5.4.2 Catena di Markov

Una Catena di Markov è un processo stocastico per sequenze. Presuppone che un'osservazione y_t a tempo t dipenda solo da un insieme finito di predecessori $L \geq 1$. Il numero di predecessori L che influenzano la nuova osservazione è detto ordine della Catena di Markov.

Una catena di Markov di ordine L è una sequenza di variabili casuali $\mathbf{Y} = Y_1, \dots, Y_T$ tali che $\forall t \in \{1, \dots, T\}$

$$P(Y_t = y_t | Y_1, \dots, Y_{t-1}, Y_{t+1}, \dots, Y_T) = P(Y_t = y_t | Y_{t-L}, \dots, Y_{t-1})$$

2.5.4.3 Modelli di Markov nascosti

Le Catene di Markov modellano i dati sequenziali assumendo che gli elementi della sequenza siano generati da un processo stocastico completamente osservabile. Nella maggior parte dei sistemi reali l'unica informazione disponibile può essere il risultato del processo stocastico ad ogni osservazione y_t mentre lo stato del sistema rimane nascosto.

Capitolo 3

Analisi del problema

3.1 Analisi traffico di rete

Nell'era digitale il traffico di rete è aumentato notevolmente e con esso gli attacchi di tipo informatico, per questo motivo è necessario trovare soluzioni per analizzare questo grande quantitativo di pacchetti che attraversano i dispositivi di rete delle aziende di grosse dimensioni. Nel mondo informatico di oggi è molto importante poter determinare rapidamente e con precisione l'origine e la portata di un potenziale attacco su una rete al fine di poterlo contrastare in modo efficace. Per fare ciò viene costruito un *audit trail* di informazioni collezionate dal traffico di rete usando una combinazione di network flow e PCAP.

Un audit trail è un file che contiene una registrazione cronologica di attività relative alla sicurezza per consentire la ricostruzione e l'esame di eventi [4].

3.1.1 Network Flow

Un flow è una sequenza di pacchetti inviati da una sorgente ad una destinazione che hanno degli attributi in comune [22]:

- indirizzo IP sorgente
- indirizzo IP destinazione
- porta sorgente
- porta destinazione

- protocollo

Se i pacchetti che attraversano un dispositivo di rete hanno questi attributi in comune possono essere raggruppati in un flow.

3.1.2 Packet Capture

Per packet capture (PCAP) si intende la cattura di traffico internet che attraversa un dispositivo di rete. Un packet capture intercetta i singoli pacchetti e li archivia. Nei sistemi operativi Unix è utilizzata la libreria **libpcap** mentre nei sistemi Windows si fa utilizzo di **WinPcap** [17].

3.1.3 NetFlow

NetFlow è un protocollo di analisi di rete introdotto da Cisco che offre la possibilità di raccogliere informazioni dettagliate sul traffico che attraversa un'interfaccia. I dispositivi di rete che supportano NetFlow possono raccogliere statistiche sul traffico ed esportarle come record verso un NetFlow collector, un server che esegue l'analisi del traffico.

Cisco definisce un flow come una sequenza unidirezionale di pacchetti che condividono tutti i seguenti 7 valori [1].

- interfaccia di ingresso
- indirizzo IP sorgente
- indirizzo IP destinazione
- protocollo IP
- porta sorgente TCP o UDP, 0 per altri protocolli
- IP Type of Service

3.1.3.1 Componenti di NetFlow

La figura 3.1 descrive un esempio di architettura dei network flow.




Figura 3.1: Architettura NetFlow

NetFlow monitor Un componente applicato a un'interfaccia che raccoglie informazioni sui flow. I NetFlow monitor sono costituiti da un record e una cache.

NetFlow exporter Aggrega i pacchetti in flows e ne esporta i record verso uno o più *flow collectors*. Quando dei pacchetti arrivano al NetFlow exporter, vengono ispezionati singolarmente per uno o più attributi che vengono utilizzati per determinare se il pacchetto è univoco o è simile agli altri pacchetti. Se il pacchetto presenta attributi simili viene classificato nello stesso flow. Dopo aver esaminato questi attributi, il NetFlow exporter li aggrega in record di flow e li salva in un database che può essere una cache NetFlow o un NetFlow collector.

La figura seguente rappresenta il funzionamento di un NetFlow exporter.

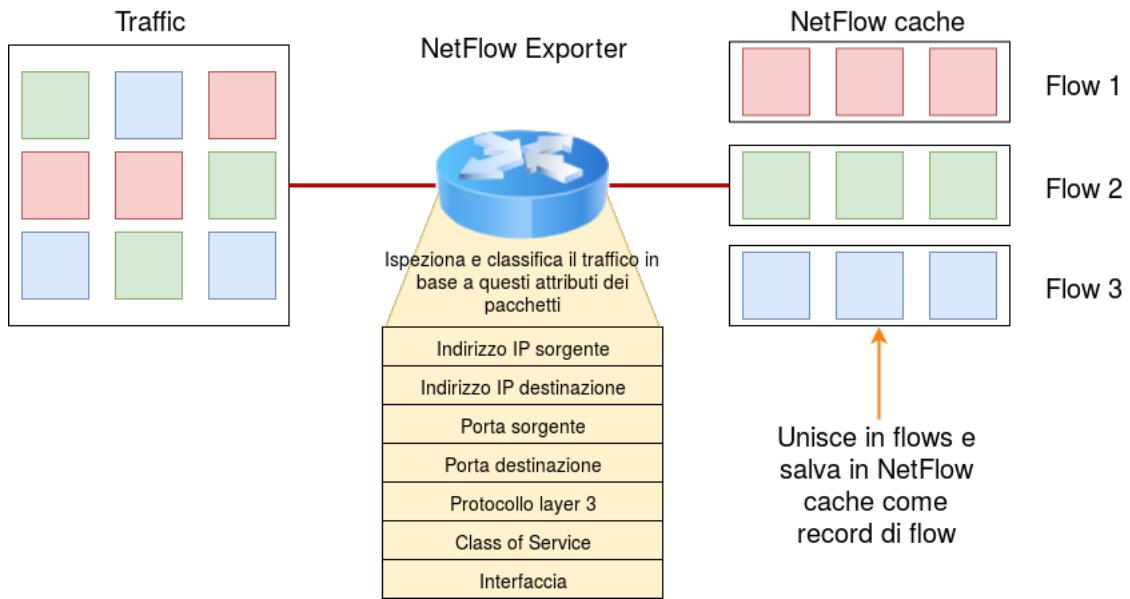


Figura 3.2: NetFlow exporter

NetFlow collector Responsabile della ricezione, conservazione e pre-elaborazione dei dati di un flow ricevuti da un *flow exporter*. Solitamente è un software separato in esecuzione su un server di rete. I record NetFlow vengono esportati in un NetFlow collector tramite protocollo UDP.

Analysis application Analizza i dati dei flows ricevuti nel contesto del rilevamento delle intrusioni o del profilo di traffico. Un esempio di Analysis application possono essere degli IDPS. Di seguito un'immagine di SolarWinds NetFlow Traffic Analyzer, un software per l'analisi dei flows.




Figura 3.3: SolarWinds NetFlow Traffic Analyzer

3.2 Strumenti di monitoraggio e analisi del traffico di rete

In questa sezione verranno presentati i software utilizzati per la cattura dei network flows. Questi software sono Open Source e sono stati usati su una distribuzione GNU/Linux.

3.2.1 Audit Record Generation and Utilization System

Argus (Audit Record Generation and Utilization System) è stato la prima implementazione del monitoraggio dei flow, è un progetto open source e multiplatforma. Quest'ultima particolarità lo rende molto interessante poichè supportando molti sistemi operativi, tra i quali Windows, MacOSX, Linux, Solaris, FreeBSD, OpenBSD, IRIX e OpenWrt, può essere adoperato in quasi tutte le reti comprendendo la maggior parte degli host. La sua architettura è di tipo server/client. Il server recupera i pacchetti ricevuti da una o più interfacce di rete disponibili su una macchina e Argus assembla poi questi pacchetti in dati binari che rappresentano dei flow. Lo scopo dei client è di quello di leggere i dati dei flow.

Argus viene utilizzato da molte università e aziende per registrare dei flow che vengono utilizzati sia nell'analisi immediata dell'utilizzo della rete, sia nell'analisi storica.

I file di Argus sono compressi con algoritmi che offrono un rapporto di compressione fino 10.000:1. La compressione di questi file è molto importante perchè tendono ad essere molto grandi e possono raggiungere dimensioni difficili da gestire.

La seguente tabella descrive i campi dei flow che argus salva su file. La prima colonna rappresenta il nome del campo del pacchetto di rete, la seconda colonna è una descrizione del campo.

campo	descrizione
StartTime	record start time
Dur	record total duration
Proto	transaction protocol
SrcAddr	source IP address
Sport	source port number
Dir	direction of transaction
DstAddr	destination IP address
Dport	destination port number
State	transaction state
sTos	source TOS byte value
dTos	destination TOS byte value
TotPkts	total transaction packet count
TotBytes	total transaction bytes
SrcBytes	src ->dst transaction bytes
srcUdata	source user data buffer
dstUdata	destination user data buffer
Label	metadata label

Campi di Argus

3.2.2 nProbe

Negli ambienti commerciali, NetFlow è probabilmente lo standard de facto per la gestione del traffico di rete. nProbe è un software in grado di raccogliere, analizzare ed esportare report sul traffico di rete utilizzando il formato standard Cisco NetFlow. È disponibile per la maggior parte dei sistemi operativi sul mercato.

La seguente tabella descrive i campi dei flow che nProbe salva su file. La prima colonna rappresenta il nome del campo del pacchetto di rete, la seconda colonna è una descrizione del campo.

campo	descrizione
IPV4_SRC_ADDR	IPv4 source address
IPV4_DST_ADDR	IPv4 destination address
IPV4_NEXT_HOP	IPv4 next hop address
INPUT_SNMP	input interface SNMP idx
OUTPUT_SNMP	output interface SNMP idx
IN_PKTS	incoming flow packets (src ->dst)
IN_BYTES	incoming flow bytes (src ->dst)
FIRST_SWITCHED	SysUptime (msec) of the first flow pkt
LAST_SWITCHED	SysUptime (msec) of the last flow pkt
L4_SRC_PORT	IPv4 source port
L4_DST_PORT	IPv4 destination port
TCP_FLAGS	cumulative of all flow TCP flags
PROTOCOL	IP protocol byte
SRC_TOS	Type of service byte
SRC_AS	source BGP AS
DST_AS	destination BGP AS
IPV4_SRC_MASK	IPv4 source subnet mask
IPV4_DST_MASK	IPv4 dest subnet mask
L7_PROTO	layer 7 protocol (numeric)
BIFLOW_DIRECTION	1=initiator, 2=reverseInitiator
FLOW_START_SEC	seconds (epoch) of the first flow packet
FLOW_END_SEC	seconds (epoch) of the last flow packet
OUT_PKTS	outgoing flow packets (dst ->src)
OUT_BYTES	outgoing flow bytes (dst ->src)
FLOW_ID	serial flow identifier
FLOW_ACTIVE_TIMEOUT	activity timeout of flow cache entries
FLOW_INACTIVE_TIMEOUT	inactivity timeout of flow cache entries
IN_SRC_MAC	source MAC address
OUT_DST_MAC	destination MAC address

Campi di nProbe

3.2.3 Confronto tra i network flow

nProbe è un software scalabile ed è stato progettato per restare al passo con le velocità multi-Gbit su hardware comune. Usando una CPU dual-core nProbe può essere usato per catturare pacchetti a 1 Gbit con perdita di pacchetti inferiore al 1%. Inoltre nProbe permette una configurazione più dettagliata e personalizzabile, permette di scegliere molti campi per l'analisi dei network flow [8].

Mentre nProbe è disponibile solo per Unix, Windows o MacOS X, Argus funziona su MacOS X, Linux, FreeBSD, OpenBSD, NetBSD, AIX, HP-UX, VxWorks, IRIS, Windows e OpenWrt, inoltre è stato portato su molte piattaforme hardware accelerate come Bivio, Pluribus, Arista, Tilera [3].

3.3 Stratosphere IPS

In questa tesi si è utilizzato Stratosphere IPS, un software open source disponibile per sistemi operativi Windows e distribuzioni GNU/Linux. In questa tesi si è fatto utilizzo esclusivo della versione per distribuzioni GNU/Linux. Stratosphere Linux IPS (slips), alla pubblicazione di questa tesi, è in alpha. È un sistema di rilevazione e prevenzione delle intrusioni comportamentale che utilizza algoritmi di machine learning per rilevare comportamenti dannosi. L'obiettivo di Stratosphere IPS è quello di creare un Intrusion Prevention System che può rilevare e bloccare comportamenti malevoli all'interno di una rete.

Fa parte di una più ampia suite di programmi che include Stratosphere Testing Framework (stf). Stf analizza i modelli comportamentali della rete alla ricerca di malware.

— introdurre nello stato dell'arte e descrivere qui in dettaglio il tipo —

Algoritmi di machine learning insieme di metodi di calcolo che utilizzano l'esperienza per migliorare le prestazioni o per effettuare delle previsioni accurate.

3.3.1 Architettura

Slips si occupa della parte di rilevazione attraverso machine learning. La parte di rilevazione e cattura del traffico viene fatta attraverso Argus che cattura i pacchetti e li rende disponibili a chiunque si connetta alla sua porta. L'idea di base è quella di leggere i flow da Argus e di inviarli a Slips. In questo modo è possibile analizzare il traffico del proprio pc e di tutte le reti su cui è in esecuzione Argus.

La figura seguente descrive l'architettura. Argus è attivo sul computer o sulla rete su cui si vuole analizzare il traffico in entrata. Questo traffico è poi salvato su un file che può essere dato in input a Slips.

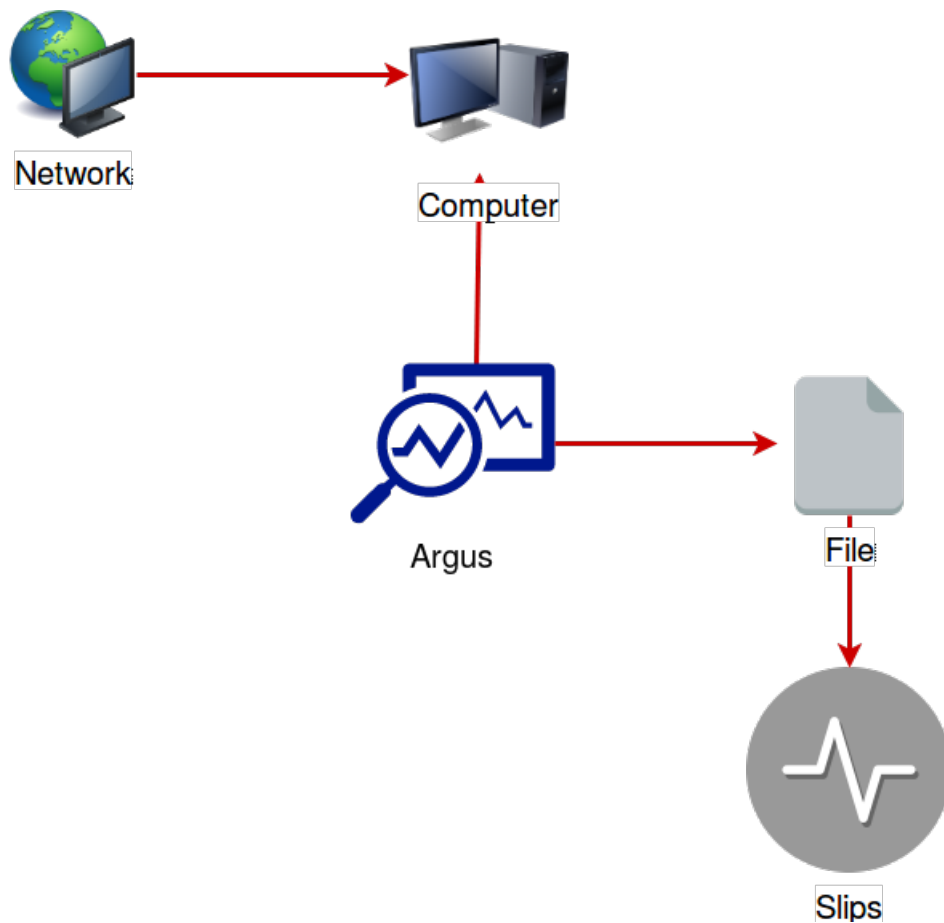


Figura 3.4: Architettura Stratosphere

3.3.2 Modelli comportamentali

Slips fa utilizzo di modelli comportamentali creati da Stratosphere Testing Framework.

Stratosphere Testing Framework è un framework di ricerca sulla sicurezza della rete per analizzare i modelli comportamentali delle connessioni di rete. Il suo obiettivo è aiutare i ricercatori a trovare nuovi comportamenti malware, etichettare tali comportamenti, creare i loro modelli di traffico e verificare gli algoritmi di rilevamento. Una volta creati e verificati i migliori modelli comportamentali di malware, questi verranno utilizzati da slips per il rilevamento. Stratosphere Testing Framework usa algoritmi di machine learning sui modelli comportamentali.

Il nucleo di *Stratosphere IPS* è composto dai modelli comportamentali di reti e algoritmi di rilevamento. I modelli comportamentali rappresentano ciò che una connessione specifica fa nella rete durante la sua vita. Il comportamento è costuito analizzando la sua periodicità, le dimensioni e la durata di ciascun flusso. Sulla base di queste caratteristiche a ciascun flusso viene assegnata una lettera e il gruppo di lettere caratterizza il comportamento della connessione.

Prendiamo come esempio una connessione generata da una botnet che ha il seguente modello comportamentale

88*y*y*i*H*H*H*y*0yy*H*H*H*y*y*y*y*H*h*y*h*h*H*H*h*H*y*y*y*H*

In questo caso ci dice che i flussi sono altamente periodici (lettere *h*, *i*), con qualche periodicità persa vicino all'inizio (lettere *y*). I flussi hanno anche una grande dimensione con una durata media. I simboli tra le lettere sono correlati al tempo trascorso tra i flussi. In questo caso il simbolo '*' significa che il flusso è separato da meno di un'ora. Con l'utilizzo di questo tipo di modelli siamo in grado di generare le caratteristiche comportamentali di un gran numero di azioni dannose.

L'immagine seguente mostra i criteri di assegnazione delle lettere per i modelli comportamentali.

	Size Small			Size Medium			Size Large		
	Dur. Short	Dur. Med.	Dur. Long	Dur. Short	Dur. Med.	Dur. Long	Dur. Short	Dur. Med.	Dur. Long
Strong Periodicity	a	b	c	d	e	f	g	h	i
Weak Periodicity	A	B	C	D	E	F	G	H	I
Weak Non-Periodicity	r	s	t	u	v	w	x	y	z
Strong Non-Periodicity	R	S	T	U	V	W	X	Y	Z
No Data	1	2	3	4	5	6	7	8	9

Symbols for time difference:

Between 0 and 5 seconds: .
Between 5 and 60 seconds: ,
Between 60 secs and 5 mins: +
Between 5 mins and 1 hour: *
Timeout of 1 hour 0

Figura 3.5: Tabella modelli comportamentali

3.4 Problematiche dovute all'utilizzo di due diversi formati

I file prodotti da nProbe e Argus, oltre ad avere formati diversi, hanno anche campi eterogenei. Stratosphere IPS si appoggia ad Argus per la cattura di file e di conseguenza può leggere file solo in formato binetflow. Se una azienda si appoggia a Cisco utilizzando nProbe non può quindi fare utilizzo di questo software, poichè non riesce a leggere file in formato differente.

Questa incompatibilità ha portato alla necessità di una conversione: i file prodotti da nProbe devono essere convertiti in file con formato usato da Argus. Questa conversione deve essere precisa ed efficiente.

3.5 Presentazione del problema

I file prodotti da nProbe hanno una struttura gerarchica fissa ben definita: ci sono 4 livelli di subdir, in cui il primo livello indica l'anno, il secondo il mese, il terzo il giorno e il quarto l'ora. All'interno dell'ultima subdir, quella delle ore, ci sono 60 file uno per ogni minuto della giornata.

La seguente immagine descrive la struttura gerarchica dei file.




Figura 3.6: Folder Structure

Capitolo 4

Soluzione proposta

In questo capitolo viene presentato il programma di conversione. La prima parte descrive le scelte effettuate per convertire i campi nell'altro formato e come automatizzare la procedura. La seconda parte introduce il concetto di programmazione parallela e le possibili soluzioni per rendere efficiente la conversione.

4.1 Conversione

Per convertire i file di nProbe nel formato utilizzato da Argus si è fatto per prima cosa uno studio sui campi degli header per individuarne le differenze. Alcuni campi sono presenti in entrambi i formati seppure con nome diverso, altri sono stati ottenuti come combinazione, mentre quelli che nProbe utilizza in più rispetto ad Argus sono stati scartati.

Di seguito è rappresentata una tabella che mostra sulla colonna di sinistra i campi dell'header di Argus, mentre sulla destra la scelta dei campi di nProbe per rappresentare i dati nello stesso formato scelto da Argus.

Tabella 4.1: Tabella di conversione

binetflow	flow
start time	first switched
duration	last switched - first switched
protocol	protocol
source address	ipv4 source address
source port	source port
direction	biflow direction
destination address	ipv4 destination address
destination port	destination port
state	-
source tos	source tos
destination tos	-
tot packets	input packets + output packets
tot bytes	input bytes + output bytes
source bytes	input bytes
source data	-
destination data	-
label	-

nProbe e Argus, oltre le differenze degli header presentano anche differenze nel formato con cui sono scritti i file.

4.2 Automatizzazione conversione

La conversione è stata automatizzata con la scrittura di uno script in Python. Si è scelto di scrivere un programma usando questo linguaggio per la facilità di utilizzo nel lavorare con i file e per le performance.

Il problema richiede lo sviluppo di un programma che converte file in modalità batch. I file hanno una struttura gerarchica per data organizzata per sottocartelle, si esegue quindi un ciclo *for* che prende tutti i file in modo ricorsivo. Dopodichè si apre il file in lettura leggendo una riga per volta, si converte il contenuto e lo si salva in una lista. Una volta terminata la lettura del file si scrive la lista contenente i dati convertiti su un nuovo file.

Si è scelto di leggere il file una riga alla volta perchè le grandi dimensioni dei file non permettono un approccio diverso. Un approccio più veloce sarebbe stato quello di leggere i file per intero nella memoria principale ma non è un approccio possibile perchè

possono presentarsi casi in cui la dimensione della RAM, soprattutto nei computer più datati, è più piccola rispetto a quella dei file.

A seguire il programma scritto in pseudocodice

Algorithm 1 Single core version

```
1: procedure HYDRA
2:   for all file in path do
3:     read data from file
4:     convert data into new format
5:     append data into new file
```

4.3 Rendere efficiente la conversione

Nel programma descritto in precedenza viene generato un solo file di output in cui vengono convertiti tutti i file dati in input. Questa soluzione è comoda perchè da migliaia di file si ottiene un solo file con i dati convertiti, ma presenta il problema di creare un file con dimensioni enormi e di difficile gestione (il file può raggiungere dimensioni tali da rendere difficile anche solo aprirlo in lettura).

Il programma è inoltre inefficiente poichè è single core e ha come collo di bottiglia la scrittura su un unico file. La soluzione proposta seppure sia teoricamente corretta non può avere un'applicazione nel mondo reale. Bisogna cambiare quindi strategia per rendere la conversione più veloce sfruttando le macchine multi core e per avere in output file di dimensioni accettabili.

4.3.1 Possibili soluzioni

Si possono pensare diverse soluzioni che migliorerebbero in modo significativo il programma visto in precedenza:

- Lavorare su chunk di file
- Meccanismi di lock
- Scrittura su file 1:1

Lavorare su chunk di file Per velocizzare il programma e sfruttare i processori disponibili si potrebbe assegnare ad ogni processore un file da leggere e convertire. Quando il processore termina la conversione dei dati scrive

sul file in output. In questo modo si dividrebbe il tempo di esecuzione sul numero di processori disponibili. Questa soluzione rende il più veloce possibile la conversione dei file ma i processori finiscono per scrivere sullo stesso file senza avere nessuna regola di precedenza, questo crea problemi perchè le scritture in output non sono ordinate e non è possibile creare modelli comportamentali affidabili. Le scritture su file devono essere ordinate e sequenziali, inoltre questa soluzione ha il problema di scrivere sempre su unico file e come detto in precedenza questo tipo di soluzione non è possibile.

Meccanismi di lock Un modo per risolvere i problemi precedenti è quello di utilizzare il concetto di semaforo. In informatica un semaforo è un tipo di dato astratto gestito da un sistema operativo multitasking per sincronizzare l'accesso a risorse condivise tra processi. È composto da una variabile intera e da una coda di processi. Quando un processo apre il file per scriverci viene impostato un semaforo che segnala che la risorsa è occupata, se un altro processore prova ad aprire lo stesso file per scriverci gli sarà negato l'accesso dal semaforo fino a quando l'altro processo non rilascerà la risorsa. In questo modo si risolve il problema delle scritture ordinate, ma c'è da tener conto che i semafori riducono la velocità di esecuzione dell'algoritmo poichè mentre un processore occupa la risorsa tutti gli altri processori devono mettersi in coda per aspettarne il rilascio. Nonostante questa soluzione rallenti l'esecuzione del programma rispetto alla soluzione precedente è comunque molto più veloce della versione single core perchè, sebbene la scrittura su file sia rallentata dai semafori, si guadagna molto tempo nella lettura e conversione dei dati dove non ne è necessario l'utilizzo, e che quindi viene effettuata alla massima velocità possibile. Questa soluzione risolve anche il problema dell'ordinamento delle scritture. Rimane il problema della scrittura su un unico file che però può essere risolto facilmente decidendo di scrivere su un nuovo file quando raggiunge una dimensione specificata. Se si implementa la divisione del file di output questa soluzione può considerarsi efficiente anche se rimane il collo di bottiglia introdotto dai semafori che costringe i processi ad aspettare in coda quando una risorsa è impegnata.

Scrittura su file 1:1 In questa soluzione ogni processore apre un file, lo legge, lo converte e scrive su un proprio file. Questa soluzione è decisamente la più semplice tra quelle proposte ed è anche la più efficiente poichè i processori non entrano mai in conflitto tra di loro cosicchè da effettuare letture, conversioni e scritture alla massima velocità possibile dalla macchina. Un problema che può creare questa soluzione è la produzione di una grande quantità di file in output. Si pensi che una sola settimana di traffico di rete, sono circa 10 mila file.

4.3.2 Scelta effettuata

Si è scelto di procedere con l'ultima soluzione presentata perchè data la grande quantità di informazioni da convertire si preferisce l'approccio più veloce a discapito dell'ordinamento finale.

Il programma, dato in input la root directory dei file, cerca ricorsivamente tutti i file e li inserisce in una coda, chiama poi una funzione a cui assegna 4 processori. La funzione ha un ciclo while che si ripete fino a quando la coda popolata da tutti i file non è vuota. Ogni processore che entra in questa funzione toglie un file dalla coda e lo elabora.

Pseudocodice del programma multi core

Algorithm 2 Multi core version

```

1: procedure HYDRA
2:   for all file in path do
3:     Queue[]  $\leftarrow$  file
4:     read data from file
5:     spawn 4 process
6:     while Queue[] not empty do
7:       filename  $\leftarrow$  Queue.get()
8:       convert data into new format
9:       append data into new file

```

La figura 4.1 descrive lo pseudocodice del programma parallelo. Ogni file da convertire è inserito in una coda a cui accedono i processori, ogni processore lavora individualmente sul proprio file da cui legge e converte i dati. La scrittura su file rimane indipendente perchè ogni processore lavora sul proprio file.

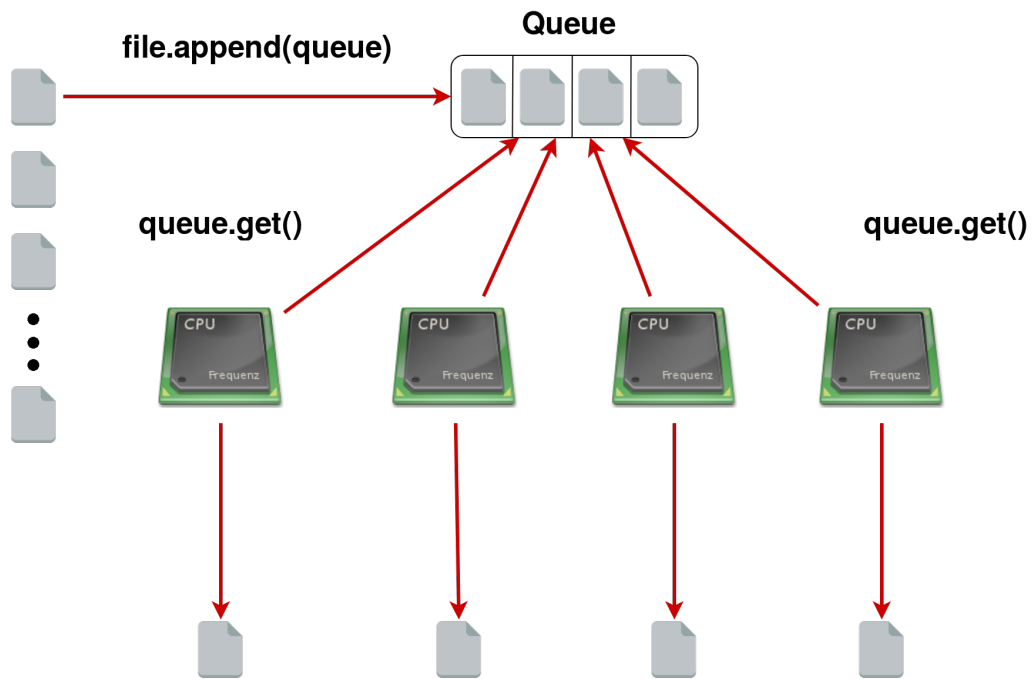


Figura 4.1: Multi core version

Capitolo 5

Esperimenti e risultati

In questo capitolo vengono presentati gli esperimenti effettuati e le prestazioni ottenuti dallo script di conversione, successivamente i test fatti con Stratosphere IPS sulla creazione di modelli comportamentali per verificare l'accuratezza della conversione dei flows.

5.1 Software utilizzati

Per lo sviluppo del programma per la conversione dei file e per l'utilizzo di Stratosphere IPS è stata creata una piattaforma dedicata alla Security Analytics tramite l'utilizzo di *VirtualBox* con una installazione del sistema operativo Ubuntu 16.04 LTS.

VirtualBox è un software gratuito e open source per l'esecuzione di macchine virtuali che supporta Windows, GNU/Linux e macOS come sistemi operativi host ed è in grado di eseguire Windows, GNU/Linux, OS/2 Warp, BSD come ad esempio OpenBSD, FreeBSD e infine Solaris e OpenSolaris come sistemi operativi guest [14].

Per controllare se la conversione viene effettuata correttamente si è usato il software Stratosphere IPS per creare e utilizzare dei modelli impiegati per fare *anomaly detection* su del traffico di rete. I flows sono stati convertiti nel formato compatibile da Argus ad nProbe e infine di nuovo ad Argus per controllare che non ci siano delle perdite di informazioni vitali che alterino il funzionamento dell'IDPS.

La figura seguente descrive il processo di conversione. Ad ogni conversione effettuata è prevista una perdita di informazioni dovuta al tipo di campi utilizzati nei diversi formati e alla loro formattazione.



Figura 5.1: Processo di conversione

5.2 Installazione Stratosphere IPS

Sulla macchina virtuale è stato installato il framework di Stratosphere IPS. Di seguito i passaggi effettuati per l'installazione [12].

- Installazione del programma git 2.7.4
`$ sudo apt install git`
- Clonazione repository github del framework
`$ git clone https://github.com/stratosphereips/StratosphereTestingFrame`
- Installazione del programma python-pip
`$ sudo apt install python-pip`
- prettytable 0.7.2-3
`$ sudo apt install python-prettytable`
- transaction 1.4.3-3
`$ sudo apt install python-transaction`
- persistent 4.1.1-1build2
`$ sudo apt install python-persistent`
- zodb 5.4.0
`$ sudo pip install zodb`
- sparse 1.1-1.3build1

```
$ sudo apt install python-sparse
```

- dateutil 2.4.2-1

```
$ sudo apt install python-dateutil
```

5.3 Installazione di Argus

Per generare i netflow dal traffico di rete è necessario avere una istanza di Argus sul computer. I seguenti passaggi sono necessari per la corretta installazione di Argus [12].

- libpcap 1.7.4-2

```
$ sudo apt install libpcap-dev
```

- bison 3.0.4

```
$ sudo apt install bison
```

- flex 2.6.0-11

```
$ sudo apt install flex
```

- Installazione dell'ultima versione di argus 3.0.8.2 dal sito <http://qosient.com/argus/dev/argus-latest.tar.gz>

- Installazione dell'ultima versione di argus-client 3.0.8.2 dal sito <http://qosient.com/argus/dev/argus-clients-latest.tar.gz>

5.4 Utilizzo del programma stf

*** Questa parte mi sembra brutta, per ogni riga dovrei caricare un'immagine presa da github, la caption è direttamente la riga sopra ***

Per eseguire il programma lo si esegue con

```
./stf.py
```

```
Stratosphere Testing Framework
```

```

      | | / |
    _ | | |
  / _ | _ |
 \ _ \ | |
... | _ \ | ...
0.1.2alpha

```

```

[*] Amount of experiments in the DB so far: 0
[*] Amount of datasets in the DB so far: 0
[*] Amount of groups of connections in the DB so far: 0
[*] Amount of groups of models in the DB so far: 0
[*] Amount of notes in the DB so far: 0
stf >

```

Per caricare un dataset si utilizza il comando

```
datasets -c /absolute/path/file.binnetflow
```

Per generare la connessione si utilizza il comando

```
connections -g
```

Infine, per generare i modelli, il comando

```
models -g
```

Per visualizzare il behavioral model si utilizza il comando

```
models -L [id]
```

```

test: stf > models -l
[] Groups of Models
+-----+-----+-----+-----+
| Group of Model Id | Amount of Models | Dataset Id | Dataset Name |
+-----+-----+-----+-----+
| 0-1               | 446              | 0         | test         |
+-----+-----+-----+-----+
test: stf >

```

5.5 Prestazioni

Come visto nel capitolo 4, il programma di conversione proposto è efficiente. In questa sezione vengono effettuati dei *benchmark* per analizzarne le prestazioni e studiare la scalabilità di una soluzione che prevede l'utilizzo di più CPU in parallelo.

5.5.1 Benchmark

Per misurare la velocità del programma si è usato come dataset 10 giorni di flows. La dimensione del dataset è di 1,7 Gb per un totale di 14400 file. Le misure sono state realizzate con il programma `/usr/bin/time`.

Il computer su cui sono stati effettuati i benchmark ha le seguenti caratteristiche:

- Linux Mint 19 Cinnamon
- Kernel 4.15.0-20-generic
- Processore Intel Core i7-3770 @ 3.40GHz
- RAM 8 Gb
- HDD 2 Tb
- AMD HD7870

È stato effettuato un benchmark per ogni core disponibile sulla CPU, a seguire i risultati:

- 1 core: 11.35.46
- 2 core: 6.02.65
- 3 core: 4.12.62
- 4 core: 3.09.79
- 5 core: 3.04.47
- 6 core: 3.04.66
- 7 core: 2.59.22

- 8 core: 2.59.33

La CPU su cui sono stati effettuati i benchmark ha 4 core fisici e 4 virtuali, si ha quindi un guadagno lineare per i primi 4 core, dopodichè il guadagno non è più lineare.

L'immagine seguente ha sull'asse delle x il numero di core e sull'asse delle y il tempo impiegato per convertire 14400 file. Come si può vedere il tempo impiegato scende in modo quasi lineare per i primi quattro core.




Figura 5.2: Tempo impiegato per la conversione rispetto al numero di core

5.5.2 Metrica delle prestazioni parallele

Sia $T(p)$ il tempo di esecuzione in secondi di un certo algoritmo su p processori. Di conseguenza sia $T(1)$ il tempo di esecuzione del codice parallelo su 1 processore. La *misura di scalabilità* o *speedup* relativo di un algoritmo parallelo eseguito su p processori si calcola come:

$$S(p) = \frac{T(1)}{T(p)}$$

In un sistema ideale, in cui il carico di lavoro potrebbe essere perfettamente partizionato su p processori, lo speedup relativo dovrebbe essere uguale a p . In questo caso si parla di speedup lineare.

Con i risultati ottenuti in precedenza si è calcolato lo speedup per ogni numero di core. La figura seguente mostra lo speedup relativo per numero di core. È possibile notare come lo speedup sia lineare per i primi quattro core e quindi ottimale, mentre aggiungendo più core si ha comunque un guadagno ma minimo.

!#!*#! Devo mostrare le formule per ogni numero o lascio solo il grafico !#!*#!




Figura 5.3: Speedup relativo per ogni core

Si definisce *efficienza* il rapporto

$$E(p) = \frac{S(p)}{p}$$

Idealmente, se l'algoritmo avesse uno speedup lineare, si avrebbe $E(p) = 1$

Più l'efficienza si allontana da 1, peggio stiamo sfruttando le risorse di calcolo disponibili nel sistema parallelo.

La figura seguente mostra l'efficienza del programma di conversione. Usando quattro core si ha un'efficienza leggermente maggiore di 0.9 mentre con l'aggiunta di altri core in questo grafico si può notare chiaramente come l'efficienza cali.




Figura 5.4: Efficienza per numero di core

La conversione in parallelo risulta molto efficiente, intorno allo 0.9. Con gli esperimenti effettuati ci si aspetta uno speedup lineare sui core fisici. Utilizzando un solo core la conversione impiega 12 minuti, mentre con quattro core si divide in quattro il tempo arrivando a 3 minuti. Le CPU di nuova generazione come AMD Ryzen vantano 32 core fisici e 32 virtuali, con questo numero di core fisici ci si può aspettare di dividere il tempo per 32, arrivando ad effettuare la conversione in 23 secondi.

5.6 Modelli comportamentali

Capitolo 6

Conclusioni

6.1 Prestazioni

Bibliografia

- [1] <https://pliki.ip-sa.pl/wiki/Wiki.jsp?page=NetFlow>.
- [2] Anatomy of a botnet. <https://web.archive.org/web/20170201233855/https://www.scribd.com/document/179124526/Anatomy-of-a-Botnet-WP-pdf>. Accessed: 2017-02-01.
- [3] Argus. <https://qosient.com/argus/>.
- [4] Atis telecom glossary - audit trail. <https://web.archive.org/web/20130313232104/http://www.atis.org/glossary/definition.aspx?id=5572>.
- [5] Federal trade commission- consumer information, "malware". <https://www.consumer.ftc.gov/articles/0011-malware>. Accessed: November 2015.
- [6] Malware definition. <https://techterms.com/definition/malware>. Accessed: 27-04-2016.
- [7] Malware revolution: A change in target. [https://docs.microsoft.com/en-us/previous-versions/tn-archive/cc512596\(v=technet.10\)](https://docs.microsoft.com/en-us/previous-versions/tn-archive/cc512596(v=technet.10)). Published: 05/20/2008.
- [8] nprobe. <https://www.ntop.org/products/netflow/nprobe/>.
- [9] Phishing definition - urban dictionary. <https://www.urbandictionary.com/define.php?term=phishing>.
- [10] Sicurezza: Virus, worm, trojan... <http://www.bloomriot.org/91/sicurezza-virus-worm-trojan.html>.
- [11] spyware. <https://searchsecurity.techtarget.com/definition/spyware>. Accessed: september 2016.
- [12] Stratospheretestingframework - github.
- [13] Tojan horse definition. <https://techterms.com/definition/trojanhorse>.
- [14] Virtualbox. <https://www.virtualbox.org/>.

- [15] What is a trojan virus? - definition. <https://usa.kaspersky.com/resource-center/threats/trojans#.VvD3e0LhDtQ>.
- [16] What is spyware? - definition. <https://www.kaspersky.com/resource-center/threats/spyware>.
- [17] Wikipedia, the free encyclopedia - pcap. <https://en.wikipedia.org/wiki/Pcap>.
- [18] Stefan Axelsson. Intrusion detection systems: A survey and taxonomy. Technical report, University of Technology Goteborg Sweden, 14 March 2000.
- [19] Witold Pedrycz (eds.) Janusz Kacprzyk. *Springer Handbook of Computational Intelligence*. Springer-Verlag Berlin Heidelberg, 1 edition, 2015.
- [20] Herbert J. Mattord Michael E. Whitman. *Principles of Information Security*. Course Technology, 4 edition, 2011.
- [21] Tom M. Mitchell. *Machine Learning*. McGraw-Hill series in computer science. McGraw-Hill, 1 edition, 1997.
- [22] G. Ruth N. Brownlee, C. Mills. Traffic flow measurement: Architecture. Technical report, University of Auckland, October 1999.
- [23] Robert Newman. *Computer Security: Protecting Digital Resources*. 2009.
- [24] Mark Stamp Peter Stavroulakis. *Handbook of Information and Communication Security*. Springer, 1st edition. edition, 2010.
- [25] Peter Norvig Stuart Russell. *Artificial Intelligence: A Modern Approach*. Prentice Hall, 2nd edition, 2002.
- [26] David Dagon Wenke Lee, Cliff Wang. *Botnet Detection: Countering the Largest Security Threat (Advances in Information Security)*. Springer, softcover reprint of hardcover 1st ed. 2008 edition, 2010.